Homework 2 - Pen and Paper

1.

$N = 6$

$y_6 \in \{P, N\}$

Classe P : $\{x_3, x_5, x_6\}$ $\quad N_P = 3$

Classe N : $\{x_1, x_2, x_4\}$ $\quad N_N = 3$

a)

$$P(C) = \frac{N_C}{N} \qquad P(y_6 = P) = 3/6 = 0.5 \qquad P(y_6 = N) = 3/6 = 0.5$$

$$P(y_j = a \mid C) = \frac{N_{y_j = a,\, C}}{N_C}$$

$P(y_3 = 1 \mid P) = 3/3 = 1$
$P(y_3 = 0 \mid P) = 0/3 = 0$

$P(y_3 = 1 \mid N) = 2/3 \simeq 0.6667$
$P(y_3 = 0 \mid N) = 1/3 \simeq 0.3333$

$$P(y_4 = a, y_5 = b \mid C) = \frac{N_{(y_4 = a \,.\, y_5 = b),\, C}}{N_C}$$

$P(y_4 = 1, y_5 = 1 \mid P) = 1/3$
$P(y_4 = 1, y_5 = 0 \mid P) = 2/3$
$P(y_4 = 0, y_5 = 0 \mid P) = 0$
$P(y_4 = 0, y_5 = 1 \mid P) = 0$

$P(y_4 = 0, y_5 = 0 \mid N) = 2/3$
$P(y_4 = 1, y_5 = 0 \mid N) = 1/3$
$P(y_4 = 1, y_5 = 1 \mid N) = 0$
$P(y_4 = 0, y_5 = 1 \mid N) = 0$

$$\mu_C = \frac{1}{N_C} \sum_{i \in C} x_i$$

$$\Sigma_C = \frac{1}{N_C - 1} \sum_{i \in C} (x_i - \mu_C)(x_i - \mu_C)^T = \begin{bmatrix} Var(y_1 \mid C) & Cov(y_1, y_2 \mid C) \\ Cov(y_1, y_2 \mid C) & Var(y_2 \mid C) \end{bmatrix}$$

classe P (x_3, x_5, x_6) :

$x_3 = [0.49, 0.56]^T$, $x_5 = [0.68, 0.33]^T$, $x_6 = [0.50, 0.46]^T$

$$\mu_P = \begin{bmatrix} \frac{0.49 + 0.68 + 0.50}{3} \\ \frac{0.56 + 0.33 + 0.46}{3} \end{bmatrix} = \begin{bmatrix} 0.5567 \\ 0.4500 \end{bmatrix}$$

$$Var(y_1 \mid P) = \frac{(-0.0667)^2 + (0.1233)^2 + (-0.0567)^2}{2} = 0.01143$$

$$Var(y_2 \mid P) = \frac{(0.1100)^2 + (-0.1200)^2 + (0.0100)^2}{2} = 0.01330$$

$$Cov(y_1, y_2 \mid P) = \frac{(-0.0667)(0.1100) + (0.1233)(-1.1206) + (-0.0567)(0.0100)}{2} = -0.01135$$

$$\Sigma_P = \begin{bmatrix} 0.01143 & -0.01135 \\ -0.01135 & 0.01330 \end{bmatrix}$$

Classe N (x_1, x_2, x_4) :

$x_1 = [0.54, 0.74]^T$, $x_2 = [0.49, 0.98]^T$, $x_4 = [0.42, 0.46]^T$

$$\mu_N = \begin{bmatrix} \frac{0.54 + 0.49 + 0.42}{3} \\ \frac{0.74 + 0.98 + 0.46}{3} \end{bmatrix} = \begin{bmatrix} 0.4833 \\ 0.7267 \end{bmatrix}$$

$$\text{Var}(y_1 | N) = \frac{(0.0567)^2 + (0.0067)^2 + (-0.0633)^2}{2} = 0.00363$$

$$\text{Var}(y_2 | N) = (0.0133)^2 + (0.2533)^2 + (-0.2667)^2 = 0.06773$$

$$\text{Cov}(y_1, y_2 | N) = \frac{(0.0567)(0.0133) + (0.0067)(0.2533) + (-0.0633)(-0.2667)}{2}$$

$$= 0.00966$$

$$\Sigma_N = \begin{bmatrix} 0.00363 & 0.00966 \\ 0.00966 & 0.06773 \end{bmatrix}$$

b)

$$h_{MAP} = \arg \max_{c \in \{P, N\}} P(c | x) = \arg \max_{c \in \{P, N\}} P(x | c) P(c)$$

$x_7 = [0.37, 0.84, 1, 1, 0]^T$:

Classe P :

$$(x_{7,(1,2)} - \mu_P) = \begin{bmatrix} 0.37 - 0.5567 \\ 0.84 - 0.4500 \end{bmatrix} = \begin{bmatrix} -0.1867 \\ 0.3900 \end{bmatrix}$$

$$|\Sigma_P| = (0.01143 \times 0.01330) - (-0.01135)^2 = 0.0001520 - 0.0001288$$
$$= 0.0000232$$

$$\Sigma_P^{-1} = \frac{1}{0.0000232} \begin{bmatrix} 0.01330 & 0.1135 \\ 0.01135 & 0.01143 \end{bmatrix} \simeq \begin{bmatrix} 573.28 & 489.22 \\ 489.22 & 492.67 \end{bmatrix}$$

$$(x - \mu_P)^T \Sigma_P^{-1} (x - \mu_P) \simeq 23.66$$

$$\mathcal{N}(x | \mu, \Sigma) = \frac{1}{(2\pi)^{m/2} \sqrt{|\Sigma|}} \exp\left(-\frac{1}{2}(x - \mu)^T \Sigma^{-1} (x - \mu)\right)$$

$$\mathcal{N}([0.37, 0.84]^T | \mu_P, \Sigma_P) = \frac{1}{2\pi \sqrt{0.0000232}} e^{-\frac{23.66}{2}}$$

$$= 33.05 \times e^{-13.88} \simeq 0.00024$$

Classe N:

$$(x_{7,(1,2)} - \mu_N) = \begin{bmatrix} 0.37 - 0.4833 \\ 0.84 - 0.7267 \end{bmatrix} = \begin{bmatrix} -0.1133 \\ 0.1133 \end{bmatrix}$$

$$|\Sigma_N| = (0.00363 \times 0.06773) - (0.00966)^2 = 0.0002458 - 0.0000933 = 0.0001525$$

$$\Sigma_N^{-1} = \frac{1}{0.0001525} \begin{bmatrix} 0.06773 & -0.00966 \\ -0.00966 & 0.00363 \end{bmatrix} \simeq \begin{bmatrix} 444.13 & -63.34 \\ -63.34 & 23.80 \end{bmatrix}$$

$$(x - \mu_N)^T \Sigma_N^{-1} (x - \mu_N)^T \Sigma_N^{-1} (x - \mu_m) \simeq 7.64$$

$$\mathcal{N}([0.37, 0.84]^T \mid \mu_N, \Sigma_N) = \frac{1}{2\pi\sqrt{0.0001525}} e^{-\frac{7.64}{2}} = 12.89 \times e^{-3.82} \simeq 0.2825$$

$$\text{Score}(P) = P(y_1, y_2 \mid P) \times P(y_3 = 1 \mid P) \times P(y_4 = 1, y_5 = 0 \mid P) \times P(P)$$
$$= 0.000031 \times 1 \times 2/3 \times 0.5 \simeq 0.0000103$$

$$\text{Score}(N) = P(y_1, y_2 \mid N) \times P(y_3 = 1 \mid N) \times P(y_4 = 1, y_5 = 0 \mid N) \times P(N)$$
$$= 0.2825 \times 2/3 \times 1/3 \times 0.5 \simeq 0.0313889$$

Como Score(N) > Score(P), x_7 é classificado como N

$x_8 = [0.40, 0.66, 1, 0, 0]^T$:

Classe P:

$P(y_4 = 0, y_5 = 0 \mid P) = 0$

$\text{Score}(P) = P(y_1, y_2 \mid P) \times P(y_3 = 1 \mid P) \times 0 \times P(P) = 0$

Classe N:

$P(y_4 = 0, y_5 = 0 \mid N) = 2/3 > 0$

Como $\mathcal{N} > 0$, $P(y_3 = 1 \mid N) = 2/3$ e $P(N) = 0.5$, (estritamente positivos) então Score(N) > 0.

Como Score(N) > Score(P), x_8 é classificada como N.

c)

Nº de Parâmetros:

Sem a suposição: Para $m = 5$ variáveis booleanas discretas, seriam necessários $2^5 - 1 = 31$ parâmetros livres por classe na distribuição conjunta $P(y_1, \dots, y_5 \mid C)$.

Com a suposição:

$$P(y_1, \dots, y_5 \mid C) = P(y_1, y_2 \mid C) \times P(y_3 \mid C) \times P(y_4, y_5 \mid C)$$

Ao nível das variáveis discretas, estimam-se apenas $(2^1 - 1) + (2^2 - 1) = 1 + 3 = 4$ parâmetros por classe

Dependências e Viés (Bias):

Preserva a dependência interna entre y_1 e y_2 (via Σ_C) e entre y_4 e y_5 (via tabela conjunta).

Introduz viés ao forçar independência condicional entre os blocos (despreza correlações cruzadas como entre y_1 e y_3).

Generalizações e Problema dos Zeros:

Em amostras pequenas ($N = 6$), reduz drasticamente a variância do estimadores e o overfitting

Mitiga o problema das probabilidades nulas ($P(x \mid C) = 0$), embora para x_8 a ausência de ($y_4 = 0$, $y_5 = 0$) na Classe P ainda resulte em $P = 0$ devido à falta de suavização (Laplace / m-estimate).

MAP vs. ML

MAP: $\arg\max_C P(x \mid C) P(C)$ vs. ML: $\arg\max_C P(x \mid C)$

Como $P(P) = P(N) = 0.5 \Rightarrow P(C) =$ constante, temos:

$$\arg\max_C P(x \mid C) P(C) = \arg\max_C P(x \mid C)$$

↳ Nenhuma alteração nas classificações de 1.b

Vantagem do ML: Não depende de priors $P(C)$, evitando viés se a distribuição do treino (N_c / N) não refletir a população real.

2.

a)

$x_1 = (1,0,0) \longrightarrow N$
$x_2 = (0,1,0) \longrightarrow N$
$x_3 = (1,1,1) \longrightarrow P$
$x_4 = (1,0,0) \longrightarrow N$
$x_5 = (1,1,0) \longrightarrow P$
$x_6 = (1,1,0) \longrightarrow P$

i)

	x_1(N)	x_2(N)	x_3(P)	x_4 (N)	x_5(P)	x_6(P)	x_7(P)	x_8(N)
x_1(N)	—	2	2	0	1	1	1	0
x_2(N)	2	—	2	2	1	1	1	2
x_3(P)	2	2	—	2	1	1	1	2
x_4(N)	0	2	2	—	1	1	1	0
x_5(P)	1	1	1	1	—	0	0	1
x_6(P)	1	1	1	1	0	—	0	1
x_7(P)	1	1	1	1	0	0	—	1
x_8(N)	0	2	2	0	1	1	1	—

$$d_H(x_i, x_j) = \sum_{m=1}^{p} \mathbb{I}(x_{im} \neq x_{jm})$$

$$\hat{y}(x) = \arg\max_{c \in \{P,N\}} \sum_{i=1}^{k} \delta(c, y_i)$$

Aplicação Leave-one-out (LOO):

- x_1 (Real = N)
  - $d=0$: $\{x_4(N), x_8(N)\}$ (2 vizinhos)
  - $d=1$: $\{x_5(P), x_6(P), x_7(P)\}$ (3 vizinhos => total 5 vizinhos para $d \leq 1$, exige desempate).
  - Usa-se $k=2$: vizinhos = $\{x_4(N), x_8(N)\}$
    => Votos: 2N, 0P => $\hat{y}_6(x_1) = N$ Correcto!

- x_2 (Real = N):
  - $d=0$: $\emptyset$
  - $d=1$: $\{x_5(P), x_6(P), x_7(P)\}$ (exatamente 3 vizinhos)
  - Usa-se $k=3$: Vizinhos = $\{x_5(P), x_6(P), x_7(P)\}$
    => Votos 3P, 0N => $\hat{y}_6(x_2) = P$ Incorreto!

- x_3 (Real = P):
  - $d=0$: $\emptyset$
  - $d=1$: $\{x_5(P), x_6(P), x_7(P)\}$ (exatamente 3 vizinhos).
  - Usa-se $k=3$: Vizinhos = $\{x_5(P), x_6(P), x_7(P)\}$
    => 3P, 0N => $\hat{y}_6(x_3) = P$ Correto!

- x_4 (Real = N):
  $d=0$: $\{x_1(N), x_8(N)\}$ (2 vizinhos); $d=1$: 3 vizinhos
  Usa-se $k=2$: Vizinhos = $\{x_1(N), x_8(N)\}$ $\Rightarrow$ Votos: 2N, 0P
  $\Rightarrow \hat{y}_6(x_4) = N$ Correto!

- x_5 (Real = P):
  $d=0$: $\{x_6(P), x_7(P)\}$ (2 vizinhos)
  $d=1$: $\{x_1, x_2, x_3, x_4, x_5\}$ (5 vizinhos).
  Usa-se $k=2$: Vizinhos = $\{x_6(P), x_7(P)\}$ $\Rightarrow$ Votos: 2P, 0N
  $\Rightarrow \hat{y}_6(x_5) = P$ Correto!

- x_6 (Real = P):
  $d=0$: $\{x_5(P), x_7(P)\}$ (2 vizinhos), $d=1$: 5 vizinhos
  Usa-se $k=2$: Vizinhos = $\{x_5(P), x_7(P)\}$ $\Rightarrow$ Votos: 2P, 0N
  $\Rightarrow \hat{y}_6(x_6) = P$ Correto!

- x_7 (Real = P):
  $d=0$: $\{x_5(P), x_6(P)\}$ (2 vizinhos), $d=1$: 5 vizinhos.
  Usa-se $k=2$: Vizinhos = $\{x_5(P), x_6(P)\}$ $\Rightarrow$ Votos: 2P, 0N
  $\Rightarrow \hat{y}_6(x_7) = P$ Correto!

- x_8 (Real = N)
  $d=0$: $\{x_1(N), x_4(N)\}$ (2 vizinhos); $d=1$: 3 vizinhos.
  Usa-se $k=2$: vizinhos = $\{x_1(N), x_4(N)\}$ $\Rightarrow$ Votos: 2N, 0P
  $\Rightarrow \hat{y}_6(x_8) = N$ Correto!

$$\text{Accuracy} = \frac{\text{Nº de previsões corretas}}{\text{Total de observações}} = \frac{7}{8} = 0.875 = 87.5\,\%$$

ii)

A accuracy não mudaria
Para variáveis booleanas $x_{im}, x_{jm} \in \{0,1\}$, a diferença absoluta apenas toma valores em $\{0,1\}$, pelo que $|x_{im} - x_{jm}|^2 = |x_{im} - x_{jm}|$.
Logo:

$$d_E(x_i, x_j) = \sqrt{\sum_{m=3}^{5} |x_{im} - x_{jm}|^2} = \sqrt{\sum_{m=3}^{5} |x_{im} - x_{jm}|} = \sqrt{d_H(x_i, x_j)}$$

como a função $f(z) = \sqrt{z}$ é estritamente crescente para $z \geq 0$, preserva integralmente a ordem (ranking) das distâncias e os empates entre todas as observações, resultando exatamente nos mesmos vizinhos e na mesma accuracy

iii)

Com a distância de Chebyshev, accuracy mudaria
Como $|x_{im} - x_{jm}| \in \{0,1\}$:

$$d_\infty(x_i, x_j) = \max_{m \in \{3,4,5\}} |x_{im} - x_{jm}| = \begin{cases} 0, & \text{se } x_i = x_j \\ 1, & \text{se } x_i \neq x_j \end{cases}$$

Consequentemente, qualquer observação distinta de x_i fica exatamente à mesma distância $d_\infty = 1$. Para x_2 e x_3 todas as restantes 7 observações do dataset ficam empatadas a distância 1, destruindo a estrutura de vizinhança de $k=3$.

Conclusão sobre Minkowski:
Para qualquer $q \in]0, +\infty[$, como $|x_{im} - x_{jm}| \in \{0,1\}$, tem-se $|x_{im} - x_{jm}|^q = |x_{im} - x_{jm}|$, pelo que:

$$d_q(x_i, x_j) = \left(\sum_m |x_{im} - x_{jm}|^q \right)^{\frac{1}{q}} = (d_H(x_i, x_j))^{\frac{1}{q}}$$

Isto demonstra que qualquer ordem finita q produz exatamente o mesmo ordenamento de vizinhos, enquanto no limite $q \to \infty$ (Chebyshev) perde-se a informação de quantas variáveis diferem, colapsando todas as distâncias não-nulas em 1.

b)

$D_{train} = \{x_1, \ldots, x_6\}$, $D_{test} = \{x_7, x_8\}$

Vizinhos em D_{train}: $y_1(x_1) = 0.54$, $y_1(x_4) = 0.42$, $y_1(x_5) = 0.68$, $y_1(x_6) = 0.50$

Observações em D_{test}: $y_1(x_7) = 0.37$, $y_1(x_8) = 0.40$

$$\hat{y}_1(x_{meow}) = \frac{1}{|N(x_{meow})|} \sum_{x_j \in N(x_{meow})} y_1(x_j)$$

Para x_7: $N(x_7) = \{x_5, x_6\}$ $(k=2)$

$$\hat{y}_1(x_7) = \frac{y_1(x_5) + y_1(x_6)}{2} = \frac{0.68 + 0.50}{2} = 0,59$$

Para x_8: $N(x_8) = \{x_1, x_4\}$ $(k=2)$

$$\hat{y}_1(x_8) = \frac{y_1(x_1) + y_1(x_4)}{2} = \frac{0.54 + 0.42}{2} = 0.48$$

$n = 2$

Mean Absolute Error (MAE):

$$MAE = \frac{1}{2} \sum_{i=7}^{8} |y_1(x_i) - \hat{y}_1(x_i)| = \frac{|0.37 - 0.59| + |0.40 - 0.48|}{2}$$

$$= \frac{0.22}{2} = \frac{0.30}{2} = 0.15$$

Root Mean Squared Error (RMSE):

$$RMSE = \sqrt{\frac{1}{2} \sum_{i=7}^{8} (y_1(x_i) - \hat{y}_1(x_i))^2} = \sqrt{\frac{(0.37 - 0.59)^2 + (0.40 - 0.48)^2}{2}}$$

$$= \sqrt{\frac{0.0484 + 0.0064}{2}} = \sqrt{0.0274} \simeq 0.1655$$